

- 2026 《人工智能导论》大作业
 - 1. 任务目标
 - 2. 具体内容
 - (1) 实施方案
 - (2) 核心代码分析
 - (3) 检测结果分析（正确率等）
 - (4) 判断依据的分析（可解释性等）
 - 3. 工作总结
 - (1) 收获、心得
 - (2) 遇到问题及解决思路
 - 4. 课程建议

2026 《人工智能导论》大作业

任务名称：可解释的谣言检测

完成组号：第 1 组（微信群接龙序号为2）

小组人员：钟睿（组长）、陈依宁、许誉文

完成时间：2026 年 6 月

1. 任务目标

本项目基于英文社交媒体谣言检测数据集 `rumor2026`，构建输入文本后输出检测结果和判断依据的系统。输出包括二分类标签和解释文本，其中 `0` 表示非谣言，`1` 表示谣言。项目关注准确率、运行效率和解释可读性。

2. 具体内容

(1) 实施方案

项目采用“baseline → Transformer 微调 → 多模型集成”的路线。首先实现 `TF-IDF + Logistic Regression` baseline，打通数据读取、训练和预测流程；随后使用

BERT/RoBERTa 微调，提升语义建模能力；最后结合传统模型和多个 RoBERTa 预测，构建两层多数投票集成，提高准确率和稳定性。

数据集包含 `train.csv` 和 `val.csv`，字段包括 `id`、`text`、`label`、`event`。传统模型使用清洗文本和 TF-IDF 特征；Transformer 模型直接对英文文本分词编码，最大长度为 256。仓库保留 baseline 和 BERT 模型，可直接推理。

(2) 核心代码分析

`src/train_baseline.py` 使用 `TfidfVectorizer` 和 `LogisticRegression` 组成 Pipeline，并输出验证集指标。`src/train_bert.py` 使用 Hugging Face `AutoTokenizer`、`AutoModelForSequenceClassification` 和 `Trainer` 完成 BERT 微调，CUDA 可用时自动使用 GPU。

`src/build_best_cuda_ensemble.py` 负责最终结果复现：先对三个基础预测文件多数投票，再将基础集成与另外两个预测成员做最终投票，生成最终指标和预测文件。`main.py`、`src/predict.py` 提供单条和批量预测入口，`src/explain.py` 生成判断依据。

(3) 检测结果分析（正确率等）

方法	Accuracy		F1
TF-IDF + Logistic Regression(baseline)	0.8429	0.8108	（类别 1）
BERT 微调	0.8504	0.8295	（类别 1）
两层多数投票集成	0.9027		0.8883

baseline 准确率为 0.8429，BERT 微调后提升到 0.8504。最终两层集成在 401 条验证集样本上达到 Accuracy 0.9027、F1 0.8883，其中非谣言类别 F1 为 0.9139，谣言类别 F1 为 0.8883，整体表现较稳定。

Validation Performance Comparison

Accuracy and class-1 F1 on val.csv




Figure 1. Accuracy and F1 improve from baseline to BERT and final ensemble.

(4) 判断依据的分析（可解释性等）

解释模块采用规则化方式生成自然语言依据。对预测为谣言的文本，系统检查是否出现 **breaking**、**urgent**、**unconfirmed** 等谣言相关词，是否包含 **maybe**、**could** 等不确定表达，以及是否缺少 **official**、**confirmed by** 等可靠来源提示。对预测为非谣言的文本，则关注是否有报道来源，以及是否缺少煽动或猜测性表达。系统输出 **Label** 和 **Reason**，使结果更易理解。

示例命令：

```
python main.py --text "Breaking news example text" --model-type bert
```

3. 工作总结

(1) 收获、心得

本项目经历了从 baseline 到深度学习模型再到集成模型的优化过程。baseline 验证流程，BERT/RoBERTa 提升语义建模能力，最终集成进一步提升效果。项目也让我们认识

到，课程项目不仅要追求准确率，还要保证代码可运行、结果可复现、文档清晰，并给出解释输出。

分工方面，钟睿（git:Rui2418）负责项目框架、BERT/RoBERTa 训练、CUDA 优化、最终集成和仓库整理；陈依宁（git:alice）负责数据预处理、传统分类器对比、TF-IDF 调参、联合搜索和错误分析；许誉文负责可解释性设计、案例整理、报告素材和展示支持。git贡献见git history。

(2) 遇到问题及解决思路

主要问题包括 CUDA 环境配置、模型文件体积较大、单一模型结果不稳定等。CUDA 问题通过检查 PyTorch 与 CUDA runtime 版本解决；大模型权重通过 Git LFS 管理；稳定性问题通过多模型投票集成缓解。最终仓库支持单条预测、批量预测和最终指标复现。

4. 课程建议

本次大作业能将机器学习、深度学习和模型评估知识应用到真实文本分类任务中。建议后续课程继续提供类似开放任务，并增加结果复现、实验记录和可解释性评价示例，帮助同学平衡模型效果、工程实现和报告表达。